# PROBABILITÉS ET STATISTIQUES

#### COMMENTAIRES

Bien que les trois parties du problème puissent, pour l'essentiel, être traitées séparément, il est conseillé de les traiter dans l'ordre de l'énoncé.

#### **NOTATIONS**

Dans tout le problème,  $P(\Theta)$  désigne la probabilité d'un événement  $\Theta$ . Si  $(\Omega, E, P)$  est un espace de probabilité, on dira que l'espace de probabilité  $(\Omega', E', P')$  est un espace de probabilité agrandi à partir de  $(\Omega, E, P)$ , si  $\Omega \subset \Omega'$ ,  $E \subset E'$ , et si la restriction  $P'_{|E|}$  de la probabilité P' à E coıncide avec P. On notera alors P' = P par abus de langage.

On désignera respectivement par E (X) et V (X) l'espérance et la variance d'une variable aléatoire X. La loi de probabilité (ou la distribution) de X sera désignée par L (X).

Le logarithme népérien de x est noté ln x. On pose de même ln  $\ln x = \ln (\ln x)$ .

## PREMIÈRE PARTIE

Soient U et V deux variables aléatoires à valeurs dans  $\mathbb{N} = \{0, 1, 2, ...\}$ . On définit la distance en variation entre les lois L(U) de U et L(V) de V par :

$$d\left(L\left(\mathbf{U}\right),L\left(\mathbf{V}\right)\right) = \sup_{\mathbf{D} \subset \mathbb{N}} \mid P\left(\mathbf{U} \in \mathbf{D}\right) - P\left(\mathbf{V} \in \mathbf{D}\right) \mid$$

On note A, B, C la partition de N définie par :

A = 
$$\{ k : k \in \mathbb{N}, P(U = k) < P(V = k) \}$$
  
B =  $\{ k : k \in \mathbb{N}, P(U = k) = P(V = k) \}$   
C =  $\{ k : k \in \mathbb{N}, P(U = k) > P(V = k) \}$ 

1º Établir les identités :

$$d (L (U), L (V)) = \frac{1}{2} \sum_{k=0}^{+\infty} |P(U = k) - P(V = k)| = 1 - \sum_{k=0}^{+\infty} \min \{P(U = k), P(V = k)\}$$

2º On suppose que U et V sont définies simultanément sur le même espace de probabilités. Montrer que :

$$d(L(U), L(V)) \leq P(U \neq V)$$

3º On pose:

$$\begin{aligned} p_{kk} &= \min \; \left\{ \; \mathbf{P} \left( \mathbf{U} = k \right) \;, \;\; \mathbf{P} \left( \mathbf{V} = k \right) \; \right\}, \qquad k \in \mathbb{N}, \\ p_{kl} &= 0 \quad \text{si} \quad k \neq l, \quad \text{avec} \quad (k, \, l) \in (\mathbf{A} \times \mathbb{N}) \; \cup \; (\mathbf{B} \times \mathbb{N}) \; \cup \; (\mathbb{N} \times \mathbf{B}) \; \cup \; (\mathbb{N} \times \mathbf{C}) \end{aligned}$$

a. Soient deux mesures de probabilités P' sur  $\Omega'=\{\ 1\ ,\dots,I\ \}$ , et P'' sur  $\Omega''=\{\ 1,\dots,J\ \}$ . On pose :

$$\begin{split} \mathbf{P}_{i} &= \mathbf{P}'\left(i\right), \quad \mathbf{Q}_{j} = \mathbf{P}''\left(j\right), \quad \text{et} \quad \mathbf{R}_{ij} = \mathbf{P}_{i} \; \mathbf{Q}_{j} \; , \\ \mathbf{1} &\leqslant i \leqslant \mathbf{I}, \quad \mathbf{1} \leqslant j \leqslant \mathbf{J}. \end{split}$$

Vérifier que R  $(i,j) = R_{ij}$  définit une mesure de probabilité sur l'ensemble produit  $\Omega' \times \Omega''$ , de marg P' et P''.

b. Montrer qu'il est possible de définir  $p_{kl}$  pour  $k \neq l$  avec  $(k, l) \in (C \times A)$ , de manière que :

— pour tout 
$$k \in \mathbb{N}$$
, 
$$\sum_{j=0}^{+\infty} p_{kj} = P(U = k)$$
,

— pour tout 
$$l \in \mathbb{N}$$
,  $\sum_{i=0}^{+\infty} p_{il} = P(V = l)$ ,

- pour tout  $k \in \mathbb{N}$  et pour tout  $l \in \mathbb{N}$ ,  $p_{kl} \ge 0$ .
- c. En déduire qu'il existe toujours un espace de probabilité sur lequel U et V, de lois L (U) et L (V) données sont définies simultanément, de manière que :

$$d(L(U), L(V)) = P(U \neq V)$$

On dira d'une loi jointe de U et V satisfaisant l'égalité ci-dessus qu'elle définit un couplage maximal de U et V

- 4º On considère dans cette question le cas particulier où :
  - la loi L (U) de U est une loi de Bernoulli :

$$P(U = 1) = 1 - P(U = 0) = p \in (0, 1)$$

où en général on désigne par  $(\alpha, \beta)$  l'intervalle ouvert d'extrémités  $\alpha$  et  $\beta$ .

— la loi L (V) de V est une loi de Poisson d'espérance E (V) =  $p \in (0, 1)$ :

$$P(V = r) = \frac{p^r}{r!} e^{-p}, \quad r = 0, 1, 2, ...$$

- a. Évaluer d (L (U), L (V)) en fonction de p. On exprimera le résultat par une expression ne faisant intervenir ni sommation infinie, ni valeur absolue, et exprimée en fonction de p et  $e^{-p}$ .
- b. Montrer qu'il est possible de définir simultanément U et V sur le même espace de probabilités, jointement à une variable aléatoire W, de manière que U et W soient indépendants et que V = WU. Déterminer la loi de W et prouver qu'une telle construction établit un couplage maximal de U et V.
- 5º On considère maintenant une suite  $X_1$ ,  $X_2$ ,...,  $X_n$  de variables aléatoires indépendantes de Bernoulli, telles que, pour i=1, 2, ..., n,

$$P(X_i = 1) = 1 - P(X_i = 0) = p_i \in (0, 1)$$

On pose  $S_n = X_1 + ... + X_n$ .

Parallèlement, on considère une suite  $Y_1$ ,  $Y_2$ , ...,  $Y_n$  de variables aléatoires indépendantes de Poisson, telles que, pour i=1, 2, ..., n,

$$P(Y_i = r) = \frac{p_i^r}{r!} e^{-p_i}, \quad r = 0, 1, 2, ...$$

On pose  $T_n = Y_1 + ... + Y_n$ .

a. Quelle est la distribution de  $T_n$ ?

b. Établir les inégalités (indication : on pourra utiliser la construction du 40, b) :

$$d (L (S_n), L (T_n)) \leq 1 - \prod_{i=1}^n (1 - d (L (X_i), L (Y_i))) \leq \sum_{i=1}^n p_i^2.$$

### DEUXIÈME PARTIE

Dans toute cette partie, on considère une suite infinie de variables aléatoires de Bernoulli indépendantes  $X_1$ ,  $X_2$ , ..., telles que :

$$P(X_i = 1) = 1 - P(X_i = 0) = \frac{1}{i}, \quad i = 1, 2, ...$$

On notera  $\iota = \sqrt{-1}$  le nombre complexe de module 1 et d'argument  $\frac{\pi}{2}$ 

On pose 
$$S_0=0$$
 ,  $S_n=X_1+...+X_n$  ,  $n=1\,,2\,,...$  , 
$$N\,(m\,,n)=S_n-S_m\,,\,0\leqslant m\leqslant n\,<\,\infty$$

On admettra que la limite :

$$\lim_{n\to\infty}\left(1+\frac{1}{2}+\frac{1}{3}+\ldots+\frac{1}{n}-\ln n\right)=\gamma$$

existe et est finie, ainsi que la formule :

$$\sum_{n=1}^{+\infty} \frac{1}{n^2} = \frac{\pi^2}{6}$$

1º Montrer que :

$$\lim_{N\to\infty}\left\{\sup_{N\leqslant m\leqslant n}\left| E\left(N\left(m,n\right)\right)-\ln\frac{n}{m}\right|\right\} = \lim_{N\to\infty}\left\{\sup_{N\leqslant m\leqslant n}\left| V\left(N\left(m,n\right)\right)-\ln\frac{n}{m}\right|\right\} = 0$$

2º On désigne par [u] la partie entière de u ( $[u] \leq u < [u] + 1$ ).

On pose:

$$M_T(s, t) = N([T e^s], [T e^t]), 0 \le s \le t, T > 0$$

a. Évaluer la fonction caractéristique E (exp (\(\ell u\) N (m, n))) de N (m, n). En déduire :

$$\lim_{T\to\infty} \mathbb{E} \left( \exp \left( \iota \ u \ M_T \left( s , t \right) \right) \right)$$

- b. Montrer que, pour tout k-uple  $0 \le s_1 < s_2 < ... < s_k$  fixé, la loi limite jointe de  $M_T$   $(s_1, s_2)$ ,  $M_T$   $(s_2, s_3)$ , ...,  $M_T$   $(s_{k-1}, s_k)$  lorsque T tend vers l'infini est un produit de lois de Poisson indépendantes, dont on précisera les paramètres.
- c. Montrer que (indication : on pourra utiliser les fonctions caractéristiques) :

$$\lim_{n \to \infty} P\left(\frac{S_n - \ln n}{\sqrt{\ln n}} < t\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{t} e^{-v^2/2} dv$$

d. Évaluer :

$$\lim_{n\to\infty} \left\{ E(S_n) - \ln n \right\}, \quad \text{et } \lim_{n\to\infty} \left\{ V(S_n) - \ln n \right\}$$

- 3º a. Montrer, en se servant des résultats obtenus dans la première partie, qu'il existe une suite de variables aléatoires Y<sub>1</sub>, Y<sub>2</sub>, ... construites sur le même espace de probabilité que X<sub>1</sub>, X<sub>2</sub>, ..., éventuellement agrandi, et telles que :
  - pour tout  $i = 1, 2, ..., Y_i$  suit une loi de Poisson d'espérance 1/i;
  - pour tout  $i = 1, 2, \dots$ , on a:

$$d\left(\mathrm{L}\left(\mathrm{X}_{i}\right),\;\mathrm{L}\left(\mathrm{Y}_{i}\right)\right)=\mathrm{P}\left(\mathrm{X}_{i}\neq\mathrm{Y}_{i}\right)\leqslant\frac{1}{i^{2}}$$

b. On pose  $T_n = Y_1 + ... + Y_n$ . Quelle est la loi de  $T_n$ ?

Montrer que la limite :

$$\lim_{n\to\infty} \{S_n - T_n\}$$

existe et est finie presque sûrement.

 $4^o$  a. On considère trois variables aléatoires  $\xi$ ,  $\eta$  et  $\zeta$ , telles que :

— pour 
$$r = 0, 1, 2, ..., P(\zeta = r) = \frac{\alpha^r}{r!} e^{-\alpha}$$
, où  $\alpha > 0$  est un nombre fixé;

— on a  $\xi \geqslant 0$ ,  $\eta \geqslant 0$ ,  $\xi + \eta = \zeta$ , la loi conditionnelle de  $\xi$  et  $\eta$  sachant  $\zeta$  étant donnée par :

$$P(\xi = m, \eta = r - m | \zeta = r) = {r \choose m} \theta^m (1 - \theta)^{r-m}, m = 0, 1, ..., r$$

où  $\theta \in (0, 1)$  est un paramètre fixé.

Déterminer la loi jointe de  $\xi$  et  $\eta$ .

b. En déduire qu'il est possible de construire sur le même espace de probabilité les suites  $X_1$ ,  $X_2$ , ..., et  $Y_1$ ,  $Y_2$ , ..., ainsi qu'une suite de variables aléatoires indépendantes  $Z_1$ ,  $Z_2$ , ..., de même loi de Poisson d'espérance 1, de telle manière que :

— pour tout 
$$n = 1, 2, ...$$
, si  $l(n) = \left[1 + \frac{1}{2} + ... + \frac{1}{n}\right]$ , alors :

$$\sum_{i=1}^{l(n)} Z_i \leqslant T_n \leqslant \sum_{i=1}^{l(n)+1} Z_i$$

- pour tout  $n = 1, 2, ..., T_n \sum_{i=1}^{l(n)} Z_i$  suit une loi de Poisson d'espérance  $1 + \frac{1}{2} + ... + \frac{1}{n} l(n)$ , et est une variable aléatoire indépendante de  $Y_{n+1}$ ,  $Y_{n+2}$ , ...
- c. Montrer que :

$$\lim_{n \to \infty} \frac{S_n}{\ln n} = 1 \quad \text{presque sûrement.}$$

oires telles Dans cette partie, on considère une suite  $\omega_1$ ,  $\omega_2$ , ...,  $\omega_n$  de variables aléatoires indépendantes et uniformément distribuées sur l'intervalle (0, 1).

1º Montrer qu'avec probabilité un, pour tout  $n=2,3,\ldots,$   $\omega_1,\ldots,\omega_n$  sont distincts. En déduire que la statistique ordonnée :

$$\omega_{1,n} < \omega_{2,n} < \dots < \omega_{n,n}$$

obtenue en rangeant  $\omega_1, \ldots, \omega_n$  par ordre croissant, est définie de manière unique presque sûrement.

2º Soit  $t \in (0, 1)$  fixé, et soit  $D_n(t)$  le nombre de variables parmi  $\omega_1, \ldots, \omega_n$ , inférieures ou égales à t.

- a. Pour i = 0, 1, ..., n, déterminer  $P(D_n(t) = i)$ .
- b. En déduire, pour i = 1, ..., n,  $P(\omega_{i,n} \leq t)$ .
- c. Montrer que cette probabilité peut s'écrire sous la forme :

$$P(\omega_{t,n} \leq t) = \frac{1}{\beta(u,v)} \int_0^t x^{u-1} (1-x)^{v-1} dx \quad t \in (0, 1)$$

où:

$$\beta (u,v) = \int_0^1 x^{u-1} (1-x)^{v-1} dx$$

et où u et v sont des paramètres dont on précisera les valeurs, en fonction de i et n. On admettra que, pour j, k entiers,

$$\beta(j,k) = (k-1)!(j-1)!/(k+j-1)!$$

3º a. Montrer que, pour tout n = 1, 2, ..., l'identité:

$$\omega_i = \omega_{r_{i-n},n} \quad , \quad i = 1, \ldots, n$$

définit presque sûrement une permutation  $r = \{r_{1,n}, \ldots, r_{n,n}\}\ de \{1, \ldots, n\}.$ 

b. Vérifier que, pour  $r = \{r_{1,n}, \dots, r_{n,n}\}$  donné, la correspondance entre  $\{\omega_1, \dots, \omega_n\}$  et  $\{\omega_{1,n}, \dots, \omega_{n,n}\}$  est biunivoque et de jacobien unité si  $\omega_{1,n} < \dots < \omega_{n,n}$ .

En déduire que la densité jointe de  $\{\omega_{1,n},...,\omega_{n,n}\}$  est n! sur l'ensemble  $\{(x_1,...,x_n):0< x_1<...< x_n<1\}$ .

- c. En déduire que  $r = \{r_{1,n}, \dots, r_{n,n}\}$  est indépendant de  $\{\omega_{1,n}, \dots, \omega_{n,n}\}$  et équidistribué sur l'ensemble de toutes les permutations de  $\{1, \dots, n\}$ .
- 4º On pose désormais R  $(n) = r_{n,n}$ , c'est-à-dire R (1) = 1 et, pour  $n \ge 2$ :

$$R(n) = \begin{vmatrix} 1 & \text{si } \omega_n < \omega_{1, n-1}, \\ i & \text{si } \omega_{i-1, n-1} < \omega_n < \omega_{i, n-1}, \\ n & \text{si } \omega_n > \omega_{n-1, n-1}. \end{vmatrix}$$

- a. Montrer que la suite  $\{R(n), n \ge 1\}$  est définie presque sûrement.
- b. Déterminer la probabilité conditionnelle  $P(R(n) \le i \mid \omega_{i, n-1} = t)$ .

En déduire  $P(R(n) \le i)$ , puis P(R(n) = i), i = 1, ..., n. Montrer que :

$$P(R(n) = n) = \frac{1}{n}, \quad n = 1, 2, ...$$

- c. Montrer que la suite  $\{R(n), n \ge 1\}$  est une suite de variables aléatoires indépendantes.
- For Pour n=2,3,..., on pose  $X_n=1$  si  $\omega_n \ge \max\{\omega_1,...,\omega_{n-1}\}$  et  $X_n=0$  autrement. On pose  $X_1=1$  Lorsque  $X_n=1$ , on dit que  $\omega_n$  est un record (sous-entendu de la suite  $\omega_1,\omega_2,...$ ), et que l'indice n correspor dant est un temps de record.
  - a. Soit  $N(n, kn) = \sum_{i=n+1}^{kn} X_i$  le nombre de records observés dans l'intervalle  $i \in \{n+1, ..., kn\}$ . En se servan

des résultats de la première et de la deuxième partie, évaluer la loi limite de N(n, kn) lorsque n tend vers l'infini. En particulier, déterminer :

$$\lim_{n\to\infty} P(N(n,kn)=r), \qquad r=0,1,2,...$$

Nota Bene: k est ici un nombre entier fixé.

b. Établir les inégalités, pour  $0 < \theta < N$ ,

$$\frac{\theta^{N}}{N!} e^{-\theta} \leqslant \sum_{r=N}^{+\infty} \frac{\theta^{r}}{r!} e^{-\theta} \leqslant \frac{\theta^{N}}{N!} e^{-\theta} \left\{ \frac{1}{1 - \frac{\theta}{N}} \right\}$$

c. En déduire que, pour tout  $\varepsilon > 0$ , il existe presque sûrement un indice  $n_{\varepsilon}$  tel que  $n \ge n_{\varepsilon}$  implique (pour  $k \ge 2$ , fixé à l'avance) :

$$N(n, kn) \leqslant \frac{(1+\varepsilon) \ln n}{\ln \ln n}$$
.

Indications : On rappelle la formule de Stirling :

$$n! = \left(\frac{n}{e}\right)^n \sqrt{2 \pi n} (1 + o(1)), \quad n \to \infty$$

On pourra faire usage des résultats du 3º de la deuxième partie.

- 6º On utilise dans cette question la suite  $\{Z_n, n \ge 1\}$  construite au 4º, b de la deuxième partie, ainsi que les notations introduites dans cette question. On supposera par la suite que  $k \ge 3$  est fixé.
  - a. On donne les évaluations numériques suivantes :

$$0,577 < \gamma < 0,578$$
,  $1,098 < \text{in } 3 < 1,099$ ,  $0,693 < \text{in } 2 < 0,694$ 

Montrer que, pour tout  $k \geqslant 3$ ,

$$1 \leq \liminf_{n \to \infty} \left\{ l(kn) - l(n) \right\} \leq \limsup_{n \to \infty} \left\{ l(kn) - l(n) \right\} \leq [\ln k] + 1$$

b. On pose, pour  $K \ge 1$ ,  $\tau_n = \sum_{i=n+1}^{n+K} Z_i$ , n = 0, 1, 2, ...

Montrer que, indépendamment de K ≥ 1 fixé,

$$\lim_{n\to\infty}\sup\left\{\frac{\ln \ln n}{\ln n}\right\}\tau_n=1 \text{ presque sûrement.}$$

c. En déduire que, pour tout  $k \geqslant 3$  fixé,

$$\lim_{n\to\infty}\sup\left\{\frac{\ln \ln n}{\ln n}\right\} N (n, kn) = 1 \text{ presque sûrement.}$$

d. Comment pourrait-on montrer que le résultat ci-dessus reste valable pour k=2?